

张敬信-《数学建模：算法与编程实现》配套课件

第 11 讲 时间序列分析 I：确定性分解

张敬信

2022 年 5 月 18 日

哈尔滨商业大学

一. 时间序列数据结构

- 为了研究某一事件的规律，依据时间发生的顺序将事件在多个时刻的数值记录下来，就构成了一个**时间序列**，用 $\{y_t\}$ 表示。
- 例如，国家或地区的年度财政收入，股票市场的每日波动，气象变化，工厂按小时观测的产量等。另外，随温度、高度等变化而变化的离散序列，也可以看作时间序列。
- 根据时间序列自身的变化规律，利用外推机制描述和预测时间序列将来的发展趋势，就是**时间序列分析**。
- 时间序列分析的三种经典算法：**确定性分解、指数平滑、ARIMA 模型**。

- base R 下的 `ts` 数据类型是专门为时间序列设计的，本质上是一个数值型向量，扩展了时刻属性使得每个数都有一个时刻与之对应。
- 用 `ts(data, start, end, frequency, ...)` 生成时间序列

参数 `frequency` 设置时间频率，默认为 1，表示一年有 1 个数据，
`frequency=12` (月度数据)，`frequency=52` (周度数则)，
`frequency=365` (日度数据)。

```

ts(data = 1:10, start = 2010, end = 2019)      # 年度数据
#> Time Series:
#> Start = 2010
#> End = 2019
#> Frequency = 1
#> [1]  1  2  3  4  5  6  7  8  9 10
ts(data = 1:10, start = 2010, frequency = 4)   # 季度数据
#>      Qtr1 Qtr2 Qtr3 Qtr4
#> 2010     1     2     3     4
#> 2011     5     6     7     8
#> 2012     9    10

```

- fpp3 生态下的 tsibble 包提供了整洁的时间序列数据结构 tsibble.
- 时间序列数据，无非就是指标数据 + 时间索引（或者再 + 分组索引）¹
- 对于分组时间序列数据，首先是一个数据框，若有分组变量需采用“长格式”作为一列，只需要指定时间索引、分组索引，就能变成时间序列数据结构。

¹多元时间序列，就是包含多个指标列。

- 现有 tibble 格式的 3 家公司 2017 年的日度股票数据，其中存放 3 只股票的 Stock 列为分组索引：

```
library(fpp3)
load("datas/stocks.rda")
stocks
#> # A tibble: 753 x 3
#>   Date      Stock  Close
#>   <date>    <chr>  <dbl>
#> 1 2017-01-03 Google  786.
#> 2 2017-01-03 Amazon  754.
#> 3 2017-01-03 Apple   116.
#> 4 2017-01-04 Google  787.
#> # ... with 749 more rows
```

- 用 `as_tsibble()` 将数据框转化为时间序列对象 `tsibble`, 只需要指定时间索引 (`index`)、分组索引 (`key`):

```
stocks = as_tsibble(stocks, key = Stock, index = Date)
```

```
stocks
```

```
#> # A tsibble: 753 x 3 [1D]
```

```
#> # Key:      Stock [3]
```

```
#>   Date      Stock  Close
```

```
#>   <date>    <chr>  <dbl>
```

```
#> 1 2017-01-03 Amazon  754.
```

```
#> 2 2017-01-04 Amazon  757.
```

```
#> 3 2017-01-05 Amazon  780.
```

```
#> 4 2017-01-06 Amazon  796.
```


```
#> # ... with 749 more rows
```

- tsibble 对象非常便于后续处理和探索:

```
stocks %>%  
  group_by_key() %>%  
  index_by(weeks = ~ yearweek(.x)) %>%      # 周度汇总  
  summarise(avg_week = mean(Close))  
  
#> # A tsibble: 156 x 3 [1W]  
#> # Key:      Stock [3]  
#>   Stock      weeks avg_week  
#>   <chr>    <week>   <dbl>  
#> 1 Amazon  2017 W01     772.  
#> 2 Amazon  2017 W02     805.  
#> 3 Amazon  2017 W03     809.  
#> 4 Amazon  2017 W04     830.  
#> # ... with 152 more rows
```


`autoplot(stocks)`

可视化



二. 预备知识

1. 差分与延迟

- **一阶差分**: $\Delta y_t = y_t - y_{t-1}$, 长度为 $T - 1$.
- **二阶差分**: $\Delta^2 y_t = \Delta y_t - \Delta y_{t-1}$, 类似的有更高阶差分。
- **季节差分 (m 步差分)**: $y_t^{(m)} = y_t - y_{t-m}$.
- **延迟算子**: 作用于时间序列, 时间刻度减小 1 个单位 (序列左移一位)

$$Ly_t = y_{t-1}, \quad L^2 y_t = y_{t-2}, \dots$$

2. 平稳性检验

(宽) 平稳性：时间序列的主要性质近似稳定，即统计性质只要保证序列的二阶矩平稳。

平稳性检验：

- **时序图检验：**若无明显的趋势性和周期性，则平稳
- **单位根检验：**通过检验时间序列自回归特征方程的特征根是在单位圆内（平稳）还是在单位圆及单位圆外（非平稳），通常用 ADF 检验或 KPSS 检验

非平稳序列的平稳化处理：

- 若时间序列呈线性趋势，均值不是常数，利用一阶差分将产生一个平稳序列；
- 若时间序列呈二次趋势，均值不是常数，利用二阶差分将产生一个平稳序列；
- 若时间序列的波动呈越来越大趋势，即方差不是常数，通常可利用取对数或开 n 次根号或 Box-Cox 变换转化为平稳序列；
- 若时间序列呈现“相对环”趋势，通常将数据除以同时发生的时间序列的相应值转化为平稳序列；
- 先用某函数大致拟合原始数据，再用 ARIMA 模型处理剩余量。

案例：2001 年 10 月—2016 年 8 月出口额数据

```
library(tidyverse)
library(lubridate)
df = readxl::read_xlsx("datas/export_datas.xlsx")
df


#> # A tibble: 188 x 2
#>   Time      export
#>   <chr>      <dbl>
#> 1 2001 年 10 月    228.
#> 2 2001 年 11 月    240.
#> 3 2001 年 12 月    245.
#> 4 2001 年 1 月     169.
#> # ... with 184 more rows
```

- 转化为 tsibble 对象

```
df = df %>%  
  mutate(Time = ymd(str_c(Time, "1 日"))) |> yearmonth()) %>%  
  as_tsibble(index = Time)  
df  
#> # A tsibble: 188 x 2 [1M]  
#>       Time export  
#>       <mth>  <dbl>  
#> 1 2001 1 月    169.  
#> 2 2001 2 月    192.  
#> 3 2001 3 月    231.  
#> 4 2001 4 月    228.  
#> # ... with 184 more rows
```

- 绘制时序图

```
autoplot(df, export)
```



显然该时间序列非平稳：既有向上的线性趋势，波动（方差）又越来越大。

采用非平稳变平稳的方法：


- 线性趋势，做 1 阶差分
- 方差越来越大，取对数²

```
df1 = df %>%  
  mutate(export = log(export))  
df2 = df1 %>%  
  mutate(export = difference(export))
```

²更好的做法是用 box-cox 变换代替取对数。

- 再来看时序图

```
autoplot(df2, export)
```



- 平稳性检验

```
df2 %>%  
  features(export, unitroot_kpss)  
#> # A tibble: 1 x 2  
#>   kpss_stat kpss_pvalue  
#>   <dbl>     <dbl>  
#> 1    0.191       0.1
```

P 值为 $0.1 > 0.05$, 接受原假设, 时间序列平稳。

时间序列分析的一般步骤：

(1) 平稳性分析：时序图观察、平稳性检验

(2) 时间序列建模

- 若平稳，依据 ACF、PACF 的截尾、拖尾情况进行模型定阶（也可以自动定阶），以确定选择哪种模型： $AR(p)$ 、 $MA(q)$ 、 $ARMA(p,q)$ 。
- 若非平稳，则
 - **确定性分析**，方法一是确定性分解，分解成长期趋势、季节变动、随机波动；方法二是进行基于移动平均思想的指数平滑法：简单、Holt 双参数、Winter 线性季节；
 - **随机性分析**：做 d 阶差分直到平稳，构建 $ARIMA(p,d,q)$ 模型；对于季节性时间序列，即存在明显的季节性（周、月、季等周期变化），则需要推广到 $SARIMA(p,d,q) \times (P,D,Q)_s$ 模型，既考虑时间步的差分、自回归、移动平均，又考虑按季节的差分、自回归、移动平均。

(3) 残差白噪声检验 (Ljung-Box 检验):

H_0 : 序列的 k 阶自相关系数均为0, 即白噪声

- 若通过检验, 则说明已经从序列中提取到充分的模型信息, 时间序列建模成功。
- 若未通过检验, 这有两种可能:
 - 残差序列可能仍存在显著的自相关性, 可以对残差序列信息进行二次提取: 建立残差自回归模型;
 - 前面建模实际上是假定残差方差相等, 但残差序列也可能具有异方差性 (ARCH 检验), 简单的有规律的异方差 (比如方差越来越大), 对原序列取对数就可以解决, 更复杂的异方差就需要单独建模: GARCH 族模型。

三. 确定性分解

时间序列可认为是受不同影响因素共同影响的叠加效果，故非平稳时间序列可按确定性因素进行简单分解：

- **长期趋势** (T_t)：表现出某种倾向，上升或下降或水平；
- **季节变化** (S_t)：周期固定的波动变化；
- **剩余部分** (R_t)：包括随机波动；

按叠加方法的不同分为：

- **加法模型** ($y_t = T_t + S_t + R_t$)：适合趋势、周期的变化幅度不随时间变化。
- **乘法模型** ($y_t = T_t S_t R_t$)：适合趋势、周期的变化幅度随时间变化。

注：适合乘法模型的时间序列，等价于取对数再用加法模型。

案例继续：出口额数据确定性分解建模

fpp3 生态提供了统一的建模框架，STL() 用于确定性分解建模。

```
dcmp = df1 %>% # 对平稳方差数据
```

```
  model(stl = STL(export))
```

```
components(dcmp)
```

```
#> # A dable: 188 x 7 [1M]
```

```
#> # Key:      .model [1]
```

```
#> # :      export = trend + season_year + remainder
```

```
#>   .model      Time export trend season_year remainder season
```

```
#>   <chr>      <mth>  <dbl> <dbl>      <dbl>      <dbl>
```

```
#> 1 stl      2001 1 月    5.13  5.36    -0.120    -0.112
```


```
#> 2 stl      2001 2 月    5.26  5.37    -0.233     0.120
```

```
#> 3 stl      2001 3 月    5.44  5.38    -0.00315   0.0687
```

```
#> 4 stl      2001 4 月    5.43  5.39     0.0327    0.0104
```

```
#> # ... with 184 more rows
```

```
components(dcmp) %>%  
  autoplot()
```



从上到下，依次是原始值、长期趋势、季节变动、随机噪声。

确定性分解之后如何预测？

分别对各部分进行建模预测：

- 对趋势进行线性回归或曲线拟合，进而往前预测
- 按季节部分的周期性规律，往前预测
- 按剩余部分的随机规律，往前预测

再将三个部分的预测值，加和或乘积（取决于加法模型或乘积模型）得到原序列的预测值。

注：时间序列的确定性分解，更高级的算法还有 SEATS 和 X11 等。

四. 指数平滑法

指数平滑法进行预测，就是对过去观测值做加权平均，随着观测值的远去，权重呈指数衰减。换句话说，观测越近，相应的权重越大。

另外，在加权时还需要分别考虑序列的水平部分、趋势部分、季节部分，各部分可按加法、乘法形式合成为总预测。

1. 简单指数平滑

适用于没有明确趋势或季节模式（即平稳）的时间序列。

简单指数平滑的加权平均形式表示为：

$$\hat{y}_{T+1|T} = \alpha y_T + (1-\alpha)\hat{y}_T = \cdots = \alpha(1-\alpha)y_{T-1} + \alpha(1-\alpha)^2 y_{T-2} + \cdots$$

其中， $\alpha \in [0, 1]$ 称为水平平滑参数。即 $T + 1$ 时刻的预测值是所有观测序列 y_1, \cdots, y_T 的加权平均，权重递减的速率由参数 α 控制。

简单指数平滑也可以写为分量形式（方便推广）：

$$\text{预测方程: } \hat{y}_{t+h|t} = \ell_t$$

$$\text{水平方程: } \ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}$$

其中， ℓ_t 表示 t 时刻的水平估计值。

2. Holt 线性指数平滑

Holt 线性指数平滑是简单指数平滑法的推广，适合带趋势的时间序列。其分量形式表示为：

$$\text{预测方程: } \hat{y}_{t+h|t} = \ell_t + hb_t$$

$$\text{水平方程: } \ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

$$\text{趋势方程: } b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$$

其中， $\alpha \in [0, 1]$ 为水平平滑系数， $\beta \in [0, 1]$ 为趋势平滑系数； ℓ_t 表示 t 时刻的水平估计值， b_t 表示 t 时刻的趋势估计值。

3. Holt-Winters 季节指数平滑

Holt-Winters 季节指数平滑是 Holt 线性趋势法的推广，适合带趋势、季节（周期）性的时间序列。

又增加一个季节方程，用 m 表示季节频率，即一年中包含的季节数，比如季度数据 $m = 4$ ，月度数据 $m = 12$ 。

季节性加入模型的方式有两种：

- 当季节变化在该时间序列中大致保持不变时，通常选择加法模型
- 当季节变化与时间序列的水平成比例变化时，通常选择乘法模型

Holt-Winters 加法模型:

$$\text{预测方程: } \hat{y}_{t+h|t} = \ell_t + hb_t + s_{t+h-m(k+1)}$$

$$\text{水平方程: } \ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

$$\text{趋势方程: } b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$$

$$\text{季节方程: } s_t = \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m}$$

其中, $k = [(h - 1)/m]$, $\gamma \in [0, 1]$ 为季节平滑参数。

- **水平方程**表示 t 时刻的水平预测值 ℓ_t , 为季节调整的观测值 $y_t - s_{t-m}$ 与非季节性预测值 $(\ell_{t-1} + b_{t-1})$ 的加权平均;
- **趋势方程**表示 t 时刻的趋势预测值 b_t , 为当前趋势值 $\ell_t - \ell_{t-1}$ 与上一期的趋势估计值 b_{t-1} 的加权平均;
- **季节方程**表示 t 时刻的季节预测值 s_t , 为当前季节指数 $(\ell_{t-1} + b_{t-1})$ 与去年同一季节 (即 m 个时刻前) 季节指数 s_{t-m} 的加权平均。

Holt-Winters 乘法模型:

$$\text{预测方程: } \hat{y}_{t+h|t} = (\ell_t + hb_t)s_{t+h-m(k+1)}$$

$$\text{水平方程: } \ell_t = \alpha \frac{y_t}{s_{t-m}} + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

$$\text{趋势方程: } b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$$

$$\text{季节方程: } s_t = \gamma \frac{y_t}{\ell_{t-1} + b_{t-1}} + (1 - \gamma)s_{t-m}$$

案例继续：出口额数据指数平滑建模

fpp3 生态提供了统一的建模框架，ETS() 用于指数平滑建模，模型公式右端通过 error(), trend(), season() 设置随机部分、趋势部分、季节部分以何种方式加入模型，“N”表示不加入模型，“A”表示加法形式，“M”表示乘法形式。

- 拟合 Holt-Winters 季节指数平滑模型

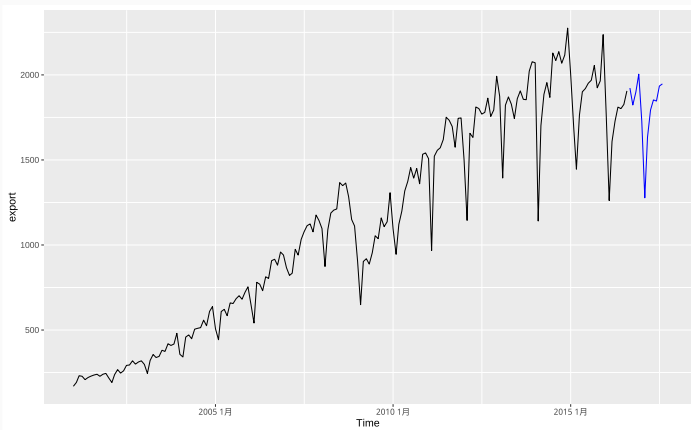
```
fit = df %>%  
  model(add = ETS(export ~ error("M") + trend("A")  
                  + season("M")))  
glance(fit)  
#> # A tibble: 1 x 9  
#>   .model  sigma2 log_lik  AIC  AICc  BIC  MSE  AMSE  
#>   <chr>    <dbl>   <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>  
#> 1 add      0.00535 -1271. 2577. 2580. 2632. 9035. 10793. 0.
```

- 模型预测，预测未来 12 期：

```
pred = forecast(fit, h = 12)
pred
#> # A fable: 12 x 4 [1M]
#> # Key:      .model [1]
#>   .model      Time      export .mean
#>   <chr>      <mth>      <dist> <dbl>
#> 1 add       2016 9 月 N(1923, 19768) 1923.
#> 2 add       2016 10 月 N(1823, 21881) 1823.
#> 3 add       2016 11 月 N(1899, 28329) 1899.
#> 4 add       2016 12 月 N(2004, 36847) 2004.
#> # ... with 8 more rows
```


- 可视化原时间序列及预测结果：

```
autoplot(pred, df, level = NULL)
```



本篇主要参阅 (张敬信, 2022), (Hyndman and Athanasopoulos, 2021), 以及包文档, 模板感谢 (黄湘云, 2021), (谢益辉, 2021).

参考文献

Hyndman, R. J. and Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. O Texts, 3 edition.

张敬信 (2022). *R 语言编程：基于 tidyverse*. 人民邮电出版社, 北京.

谢益辉 (2021). *rmarkdown: Dynamic Documents for R*.

黄湘云 (2021). *Github: R-Markdown-Template*.